

E5 · 운영 선택 심화

어디에서 실행할까요?

SW·EDA 작업의 배치와 운영을 비교합니다.

경계 → 실패 → 측정

준비 · E0–E2 · 네트워크·권한 기초
실습과 도식은 가상 교육 예시 · 2026.10.12

필요 조건부터 수치로 정의



질문	PoC에서 정할 값
어떤 작업인가?	과제·정답·허용 자료·사용자
얼마나 몰리는가?	동시 작업·입력 크기·도구 시간
무엇이 성공인가?	처리율·오답률·지연 분포
언제 멈추나?	시간·비용·실패·사람 인계

사내 서버 수·100 RPM·모델 점수는 **해당 환경의 근거가 있어야** 씁니다.

추론·도구·자료의 세 위치



모델

추론 위치

외부 API
또는 내부 서버

→

Agent·도구

실행 위치

사용자 PC
또는 작업 서버

→

자료

보관·이동

원본 저장소
필요한 문맥과 결과

모델이 공개됐는지보다 **실제 데이터 흐름**을 먼저 그립니다.

E5 · 운영 선택 심화

두 배치안을 같은 기준으로



기준	외부 모델 + 내부 도구	내부 모델 + 내부 도구
추론 자원	외부 제공자	내부에서 확보·운영
자료 이동	허용한 문맥이 외부 호출로	내부 추론 경로 확인
지연	모델·네트워크·도구·큐	모델·도구·큐
공통 책임	권한·검증·종료	권한·검증·종료

내부 실행도 **전체 지연이 0이 되는 것은 아닙니다.**

통제는 어느 계층에 있나요?



API·어댑터

요청 검사

인증·인가
스키마·도구 허용 목록

실행 프로세스

접근 제한

파일·네트워크 권한
자원·사용자 제한

작업 흐름

결과 판정

원문·테스트·종료
실행 기록

MCP와 컨테이너는 구성 요소. **완전 격리·유출 0% 보장은 아닙니다.**

E5 · 운영 선택 심화

도구 오류의 원인을 분리



관찰	가능한 위치	확인할 증거
없는 도구 이름	모델·도구 목록	등록 목록·요청
잘못된 인자	스키마·어댑터	검사 오류·인자
접근 거부	인증·인가	정책·반환 상태
빈 결과	자료·실행 실패	원문 존재·종료 코드

모든 오류를 **모델의 추론 부족**으로 설명하지 않습니다.

요청 제한과 시간 초과



요청 수 제한

429 등 제한 응답

허용 요청량·동시성 확인
큐·백오프·예산

응답을 못 기다림

timeout

클라이언트·서버·도구
느린 구간을 구분

제한 응답과 timeout은 **같은 실패 상태가 아닙니다.**

느린 곳을 구간별로 측정



대기

큐 + 네트워크

동시 작업 수
왕복 시간

→

작업

모델 + 도구

추론 시간
도구 처리 시간

→

반복

추가 시도

검증·재시도
총 소요 시간

> 가상 계산: 직렬 1회 6초 × 3회 = 18초. 실제 대기·재시도는 따로 더해집니다.

평균 한 값 대신 **중앙값·꼬리 지연·실패율**을 함께 봅니다.

문맥이 커질 때 무엇을 줄일까?



문서 선택

필요한 범위

관련 파일·절만
접근 범위 안에서

→

입력 구성

분할·요약

예산 안에 구성
원문 링크 보존

→

실패 처리

한도 응답

거부·절단·압축을 구분
다른 경로 또는 인계

문맥 초과가 항상 **이전 대화 삭제**를 뜻하지는 않습니다.

실패에 맞춰 대응을 고릅니다



유형	대응	끝내는 조건
일시 제한·연결 오류	제한 재시도·백오프	횟수/시간 예산
권한·형식·잘못된 버전	차단·수정 요청	유효한 입력 없음
모호한 사양·근거 부족	사람에게 질문	확인 대기
취소·무진전	상태 저장 후 종료	명시적 중단

스스로 고칠 수 없는 실패에는 **인계 경로**를 둡니다.

측정값으로 대안을 비교



측정 항목	기록할 조건
정확도·인계율	과제·정답·모델·버전·반복 수
지연·처리량	입력 크기·동시성·도구 시간
자원·운영비	CPU/GPU·메모리·호출 비용
잔여 제약	권한·모델 오류·외부 API 정책

서버를 늘려 해결되는 병목과 **그대로 남는 문제**를 나눕니다.

E5 · 운영 선택 심화

작은 PoC로 결정을 내립니다



범위

한 작업

SW 로그 또는
EDA 문서 질의

비교

두 배치안

같은 입력·완료 기준
성공과 실패 모두

결정

측정 후 선택

성능·운영·자료 경계
잔여 위험을 함께

PDF 내려받기 ↓ | 과정 목록 ↗

제출: 배치도 · 집행 위치 · 실패/종료 · 측정 계획 · 판단 기준.